

作业一：文本分类实验报告

姓名：李梓菲

学号：2312183

一、实验目的

本次作业旨在理解和掌握不同文本表示方法在文本分类任务中的基本原理与实际效果。我们分别使用传统词袋模型、Word Embedding / Word2Vec，以及预训练语言模型对文本进行表示，并训练文本分类模型。

- 1. 理解不同文本表示方法的基本思想；
- 2. 掌握文本分类任务的基本实验流程；
- 3. 熟悉 Logistic Regression 在文本分类中的使用；
- 4. 掌握 Word2Vec、GloVe 等词向量的基本使用方法；
- 5. 熟悉 BERT 类预训练语言模型的 Fine-tuning 流程；
- 6. 能够使用 Accuracy 和 Macro-F1 对文本分类模型进行评价；
- 7. 能够对不同文本表示方法的性能进行基本比较和分析。

二、数据集与预处理

2.1 数据来源和划分

分类数据为 HW-1/nyt.csv，包含 text 和 label；HW-1/ag.csv 只有 text，不作为分类样本，不参与 NYT 的划分和 Accuracy / Macro-F1 评价。

文件	有效文档数
NYT	11,519
AG News	90,000

上述长度由实际文件统计得到，数据摘要保存在 analysis_artifacts/data_profile.json。NYT 类别分布明显不均衡，sports 约占 75%。

固定随机种子 42，使用两次带 stratify 的 train_test_split：先将 NYT 随机分为 80% 训练与 20% 留出，再把留出集等分为验证、测试。三部分调用同一个 make_split，并保存实际索引。

若分别向下取整，80%/10%/10% 得到 9,215/1,151/1,151，剩余两条分别落入验证集和测试集。

集合	business	politics	sports	合计
全部 NYT	1,429	1,451	8,639	11,519
Training Set	1,143	1,161	6,911	9,215
Validation Set	143	145	864	1,152
Test Set	143	145	864	1,152

分层使验证、测试集类别比例接近总体。报告中的样本编号是 CSV 读入后有效样本的零起始索引，不是含表头的文件行号。

2.2 预处理操作

处理	Task 1: 词袋	Task 2: 词向量
小写化	是	是
切词	按空白切分： text.lower().split()	正则：(?u)\b\w\w+\b
标点	保留，包括附着在词上的标点	正则将标点作为分隔；下划线属于 token
停用词	不删除	不删除
数字	不删除	保留长度至少为 2 的数字 token
单字符 token	保留	不保留
词干化、词形还原	均不做	均不做
长文本截断	不截断	不截断
词表/特征学习范围	仅训练集；两种词袋共用同一个词表	NYT Word2Vec 仅训练集；AG Word2Vec 使用全部 AG；GloVe 固定不再训练

三、Task 1: Bag of Words

3.1 词表

在 NYT 训练集按空白分词建立一次词表 V 。先生成词频 CSR 稀疏矩阵；Binary 直接复制矩阵并将所有非零值改为 1。因此两套方案的词项、列顺序和未知词处理完全一致，差别仅在矩阵数值。

Binary 的第 i 维为：

$$x_i^{\text{binary}}(d) = \begin{cases} 1, & w_i \in d, \\ 0, & w_i \notin d. \end{cases}$$

Freq 的第 i 维为：

$$x_i^{\text{freq}}(d) = \text{count}(w_i, d).$$

3.2 实验方法

特征构建与分类流程 本部分分别训练 Binary 和 Freq 两个文本分类器。先读取 NYT 文本和标签，使用第 2.1 节的固定分层划分，再通过 CountVectorizer 在训练文本上建立 227,613 维词表。训练、验证、测试文本均映射到这个词表；验证和测试中的新词直接忽略。Freq 保留每个词的出现次数，Binary 将非零词频改为 1，两者均以 CSR 稀疏矩阵输入分类器，不做文档长度归一化。这样，两种方法使用完全相同的样本和特征列，可以比较“是否出现”和“出现多少次”对分类的影响。

多分类逻辑回归 两个分类器均使用 scikit-learn 的 LogisticRegression。对于文档特征 $\mathbf{x}$ ，模型为 business、politics、sports 三个类别分别学习权重 $\mathbf{w}_k$ 和偏置 b_k ，先计算线性分数，再通过 softmax 得到类别概率

训练设置与模型选择 两种表示各自独立训练分类器，统一使用 lbfgs 求解器、L2 正则、`tol=1e-4`、`max_iter=4000`、`random_state=42`、`class_weight=None`，保留默认偏置项，不进行过采样或类别加权。对每种表示分别尝试 $C \in \{0.1, 1, 10\}$ ，每个候选只使用 9,215 篇训练新闻及其标签拟合；在 1,152 篇验证新闻上计算 Accuracy 和 Macro-F1。

只允许已收敛的候选参与选择，优先选择验证 Macro-F1 最高者，平局时依次选择 Accuracy 较高、C 较小者。最终 Binary 选择 $C=0.1$ ，Freq 选择 $C=1$ 。

选定后直接保留对应的训练集模型，不将验证集并入训练集重新拟合，再在 NYT Test Set 上进行最终评价。Accuracy 是预测正确的样本比例；Macro-F1 是三个类别各自 F1 的算术平均，每个类别权重相同，因此能补充反映少数类的识别效果。学习曲线固定已建立的词表与选定 C，在训练集的 20%、40%、60%、80%、100% 分层子集上训练分类器，并始终在同一验证集上评价。上述训练、选模和评价由 experiment_utils.py 的 select_and_evaluate 统一执行。

3.3 实验结果

下表是按空格分词、统一求解器和验证选择协议的实验结果。


文本表示	选定 C	Validation Accuracy	Validation Macro-F1	Test Accuracy	Test Macro-F1
Binary Bag-of-Words	0.1	0.9835	0.9598	0.9905	0.9774
Word Frequency	1	0.9826	0.9604	0.9922	0.9811

Binary、Freq 的最终模型分别迭代 43、129 次收敛，没有沿用旧报告“词频达到迭代上限但已稳定”的未经充分支撑结论。

实验中 Freq 的测试 Accuracy 比 Binary 高约 0.0017，Macro-F1 高约 0.0037。

分类器学习曲线

LR learning curves: fixed text features; test excluded



横轴是监督训练样本数：1,843、3,686、5,529、7,372、9,215。每个点使用种子 42 从训练集分层抽样，重新训练一个分类器；同一行两张图分别显示 Accuracy 与 Macro-F1，虚线为该训练子集的成绩，实线为固定验证集的成绩。

Freq 的验证 Macro-F1 从 0.9232 上升至 0.9604；Binary 从 0.9378 上升至 0.9598。小样本时 Binary 较好，样本增加后 Freq 的重复词信息变得更有用。曲线存在波动，例如 Binary 的 80% 点略低于 60% 点，不能简单断言更多训练样本一定带来单调提升。

两种词袋模型在训练子集上的 Accuracy 和 Macro-F1 都接近 1.0，这说明高维词项能充分拟合已见新闻，但仍存在训练与泛化表现差距。

3.4 bad case

测试集共有 1 条 Binary 对而 Freq 错、3 条 Freq 对而 Binary 错、8 条两者都错，其余 1,140 条两者都对。这与两者分别错误 11 条、9 条相符。下面给出一些错误的例子。

NYT 样本索引	文章主题	真实类别	Binary	Freq	对比类型
4252	Fix the Debt、企业游说、税改与财政赤字	politics	politics	business	Binary 对、Freq 错
6645	Walmart 罢工、劳动关系调查和公司雇员	business	politics	business	Freq 对、Binary 错
6655	GSN 电视台游戏节目与新季度节目计划	business	sports	business	Freq 对、Binary 错
995	伦敦奥运会的经济收益、政府投资	sports	business	business	两者都错

样本 4252：正文讨论前议员参与财政赤字与税改游说，同时多次提到企业。Binary 中 republican、washington、state 支持 politics；其 politics 减 business 的完整 logit 差为 +1.0276，预测正确。Freq 中 companies 出现 9 次，对该差值的贡献为 -2.7794，完整差值为 -5.1357，预测 business。它说明重复出现的商业主题可与政治主题竞争。

样本 6645：新闻开头为“walmart illegally disciplined and fired employees over strikes and protests”，包含劳工部门、州和抗议活动。Binary 的 business 减 politics 分数仅为 -0.0491，处于较近边界；Freq 中 company 出现 4 次，贡献 +2.5134，labor 出现 6 次，贡献 +1.4980，完整差值为 +7.5778，恢复 business。频次可以强化企业和劳动关系的持续主题，不过不能把两个关键词当成足以解释整篇预测的唯一因素。

样本 6655：文章讨论电视台节目，不是体育赛事。Binary 中 game、season 对 sports 提供了较强支持，business 减 sports 为 -0.6813；Freq 的完整差值为 +3.9387，预测 business。这里 game、season 的多义性说明没有词序和上下文的词袋容易受到局部表面词干扰。

样本 995：文章以奥运会为对象，但重点讨论投资与经济收益。Freq 中 games 出现 8 次，支持 sports 的贡献为 +2.1416；government 出现 5 次，贡献 -2.2116，billion 出现 7 次，贡献 -1.1444，完整 sports 减 business 差为 -0.6510。Binary 同样偏向 business。应当结合主事件和叙述重心分析，而不能因为出现经济词就认为标注必然错误。

四、Task 2: Word Embedding 文本分类

4.1 三组词向量及训练范围

三组词向量维度均为 100。GloVe 使用 Stanford glove.6B 的 100 维版本；

两组 [gensim Word2Vec](#) 分别使用 NYT 的 9,215 篇训练文档和 AG 的全部 90,000 篇无标签文档。

Word2Vec 参数	两组共同设置
算法、维度	Skip-gram, 100 维
窗口	最大 5，动态缩小窗口
最小词频	min_count=3
负采样	5 个；噪声分布为词频的 0.75 次幂
高频词下采样	sample=1e-3
训练轮数	5 epochs
学习率	初始 0.025、最低 0.0001
复现设置	seed=42、workers=1、固定初始化哈希

文档平均向量与未知词

设文档为 $d = (w_1, \dots, w_m)$ ，有效词位置集合为 $I(d) = \{i : w_i \in V_e\}$ 。文档表示为：

$$\mathbf{e}(d) = \frac{1}{|I(d)|} \sum_{i \in I(d)} \mathbf{e}(w_i) \in \mathbb{R}^{100}.$$

按有效词的出现次数平均，重复词重复计入；OOV 跳过，分母不计入未知词。无有效词时返回 100 维零向量。本次所有训练、验证和测试文档都有有效词。程序不对平均向量额外进行 L2 归一化或标准化。

三组训练矩阵均为 9215×100 ，验证、测试为 1152×100 。模型分类器与 Task 1 共用同一求解器和验证选择规则。

4.2 实验方法

两阶段训练流程。 本部分采用“获取词向量 → 文档平均池化 → 逻辑回归分类”的流程，分别构建 GloVe、AG Word2Vec、NYT Word2Vec 三个分类方案。首先切词；随后获取第 4.1 节的 100 维词向量，并把每篇 NYT 新闻转换为一个 100 维稠密向量。

GloVe 直接读取已训练好的向量，当前实验不更新其参数。两组 Word2Vec 使用 gensim 的 Skip-gram 与负采样：从文档内的中心词和上下文构造正样本，再采样噪声词作为负样本，通过第 4.1 节的目标学习词的分布式表示。NYT Word2Vec 只使用 NYT 训练文本，AG Word2Vec 使用全部 AG 文本；二者均不使用分类标签。训练完成后取输入词向量进行平均池化，词向量参数在后续分类训练中保持固定。

平均词向量上的逻辑回归。 对每一种词向量来源，分别训练一个独立的三分类 LogisticRegression。其 softmax 概率、交叉熵与 L2 正则目标均与第 3.2 节相同。因此，分类器学习的是 100 个语义维度与新闻类别之间的线性关系。平均操作保留重复词的贡献，并通过除以有效词数减弱文档长度影响。

选模与测试流程。 三个分类器均使用与 Task 1 完全相同的 lbfgs、L2、收敛阈值、最大迭代次数及 $C \in \{0.1, 1, 10\}$ 候选范围。分别以 NYT 训练标签拟合，以验证 Macro-F1、验证 Accuracy、较小 C 的顺序选择已收敛候选；本次三组均选出 $C=10$ 。保留选中的训练集模型后，在 NYT Test Set 上报告 Accuracy、Macro-F1 和各类 F1。测试标签不参与词向量训练或 C 的选择，查询固定 GloVe 中的测试词向量也不更新其参数。

本部分包含两个不同的优化过程：Word2Vec 根据无标签文本中的词共现关系学习词向量，逻辑回归根据 NYT 标签学习分类权重。两阶段独立执行，分类损失不会反向更新词向量。LR 学习曲线仅改变有标签训练样本量，固定已经获得的词向量和选定 C；Word2Vec 的每轮负采样损失另行记录，两类曲线的含义见第 4.5 节。

4.3 实验结果

词向量来源	选定 C	Validation Accuracy	Validation Macro-F1	Test Accuracy	Test Macro-F1
Pre-trained GloVe	10	0.9774	0.9500	0.9861	0.9669
Word2Vec trained on AG News	10	0.9731	0.9402	0.9792	0.9506
Word2Vec trained on NYT	10	0.9783	0.9499	0.9887	0.9718

GloVe、AG Word2Vec、NYT Word2Vec 的分类器分别迭代 82、40、57 次收敛。

下面展示三种方法的覆盖率，token 覆盖率按出现次数统计，不同词覆盖数按去重词项统计。GloVe 的 400,000 是公开词表总量；59,666 是本次查询时载入的 NYT 所需向量数量。


词向量来源	词向量词表	Test token 覆盖率	Test 不同词 覆盖数	零向量 文档
Pre-trained GloVe	400,000 (载入所需的 59,666)	99.77%	27,212 / 28,107	0
Word2Vec trained on AG News	29977	96.63%	17,657 / 28,107	0
Word2Vec trained on NYT	35703	98.98%	22,843 / 28,107	0

下表是测试结果，我们分层给出结果。可以看到 NYT Word2Vec 最好，GloVe 次之，AG Word2Vec 最低。NYT 相比 GloVe 的提升同时出现在三类；相较 AG，其少数类 F1 差距尤其明显。不过验证集 GloVe 的 Macro-F1 略高于 NYT。

词向量来源	business F1	politics F1	sports F1
Pre-trained GloVe	0.9481	0.9550	0.9977
Word2Vec trained on AG News	0.9247	0.9306	0.9965
Word2Vec trained on NYT	0.9547	0.9619	0.9988

LR 学习曲线


LR learning curves: fixed text features; test excluded



与 Task 1 相同，这些曲线固定词向量和 C。NYT 的验证 Macro-F1 从 20% 的 0.9413 提升至 80% 的 0.9544，100% 时为 0.9499；GloVe、AG 也存在平台和波动。曲线说明较少有标签样本也能在固定向量上获得较好分类，但不保证增加样本时验证集指标单调增加。

Word2Vec 训练损失

Word2Vec per-epoch loss (unnormalized; compare trends within each corpus)



图中是 gensim 返回的每轮未归一化 SGNS 损失统计。为避免多轮累计 float32 统计器饱和，每轮开始重置损失累计值。AG 的报告损失从约 2,735 万降到约 2,540 万，第 5 轮比第 4 轮略高；NYT 从约 4,155 万降至约 4,014 万。

通用、同语料与不同来源语料的比较

通用 GloVe 与自行训练向量。 固定 C=1 的验证对照中，GloVe Macro-F1 为 0.9477，高于 NYT 的 0.9303；统一验证搜索后，两者均选择 C=10，测试集 NYT Macro-F1 为 0.9718，高于 GloVe 的 0.9669。

NYT 与 AG。 两者都是新闻语料，它们的来源、主题及实体分布不同。NYT 使用的训练文档更少，但 token 数更多，且与分类文本来自同一数据源，测试覆盖率为 98.98%，AG 为 96.63%。在 NYT 向量词表中保留、但 AG 保留词表中缺失的高频 NYT 词包括 girardi、djokovic、mcilroy、2013、twitter 等，反映人物、事件和词形分布差异。NYT 的测试 Macro-F1 比 AG 高约 0.0213。领域接近、训练 token 总量、语料结构和覆盖率都可能影响结果。

五、Task 3：BERT-base 文本分类微调

5.1 采用模型

本部分采用 [google-bert/bert-base-uncased](#)，最大长度 64，完整训练 3 epochs。BERT 编码器与分类头一起更新。加载后三分类模型参数量为 109,484,547。

编码器包含 12 个 Transformer 层，隐藏维度 768，注意力头数 12；分类头将 768 维表示映射到三个类别。沿用 Task 1/2 的种子 42、同一分层划分，共 9,215/1,152/1,152 篇新闻。使用预训练模型配套的 uncased WordPiece tokenizer，内部小写化与子词切分。

5.2 实验方法

端到端训练。 文本经 BERT 后取最后一层 [CLS] 的隐藏状态，通过 BERT pooler 的线性变换与 tanh、dropout，再由新初始化的三分类线性层输出 logits。使用三类 softmax 交叉熵，反向传播更新全部 BERT 参数和分类头；这与前两部分固定表示后单独训练逻辑回归的方式不同。


训练设置。 使用 PyTorch 2.6.0+cpu、Transformers 4.49.0，batch size=16，AdamW 学习率 2e-5、weight decay=0.01（bias 和 LayerNorm.weight 不衰减）、梯度范数裁剪 1.0，不使用学习率调度器、类别加权或过采样。固定 Python/NumPy/PyTorch 种子 42，启用确定性算法，训练集每轮随机打乱；在 cpu 上运行，线程数 6。

验证选择与最终测试。 每轮末在 eval 模式下评估验证集，以验证 Macro-F1 最高者保存最佳检查点；平局时依次比较 Accuracy、较早 epoch。本次选中第 3 轮，但始终完成规定的 3 轮训练。随后重载所选检查点，记录其验证成绩，并仅在此时计算最终 test 成绩。测试标签不参与参数更新、epoch 选择或训练曲线。

5.3 实验结果与训练曲线

模型	选定 epoch	Validation Accuracy	Validation Macro-F1	Test Accuracy	Test Macro-F1
BERT-base-uncased fine-tuning	3	0.9714	0.9365	0.9748	0.9435

Epoch	Training loss	Validation loss	Validation Accuracy	Validation Macro-F1
1	0.1481	0.1859	0.9488	0.8789
2	0.0555	0.1366	0.9714	0.9360
3	0.0235	0.1666	0.9714	0.9365



训练损失是该轮各 batch 的交叉熵按样本数加权的平均，计算过程中参数持续更新、dropout 开启；验证损失是在轮末固定参数、关闭 dropout 的 eval 模式计算。

从第一到第二轮，验证 Accuracy 从 0.9488 上升到 0.9714，Macro-F1 从 0.8789 上升到 0.9360，说明训练产生了明显收益。第二到第三轮，训练损失从 0.0555 降至 0.0235，但验证损失从 0.1366 升至 0.1666；验证 Accuracy 不变，Macro-F1 仅提升约 0.0004。这显示继续拟合训练样本后，验证分类收益已接近平台，并出现验证交叉熵恶化的迹象。Macro-F1 只依赖最终类别，交叉熵还反映概率分布，因此两者可以朝不同方向变化；不能因为训练损失更低就断言泛化一定更好。

类别	Test Precision	Test Recall	Test F1	样本数
business	0.8742	0.9720	0.9205	143
politics	0.9692	0.8690	0.9164	145
sports	0.9942	0.9931	0.9936	864

测试混淆矩阵的行是真实类别，列是预测类别：

真实类别	business	politics	sports
business	139	2	2
politics	16	126	3
sports	4	2	858

本次 BERT 配置的验证和测试两项指标均低于前五种方案。相对 Freq，测试 Accuracy 低约 1.74 个百分点，Macro-F1 低约 3.76 个百分点；相对 NYT Word2Vec，分别低约 1.39 和 2.83 个百分点。BERT 的上下文表示允许同一个词随语境变化，并用注意力结合输入中的词序和邻近信息；词袋没有这一机制，静态平均向量也不能对多义词作上下文区分。但本实验只读取新闻开头 62 个内容 token，无法使用截断部分的关键人名、事件或主题线索。前两部分读取完整正文，因此实际结果同时受到表示能力、可见信息量和监督训练方式的影响。

六、实验总结

当前已完成方案实验结果：

方案	Validation Accuracy	Validation Macro-F1	Test Accuracy	Test Macro-F1
T1-Binary	0.9835	0.9598	0.9905	0.9774
T1-Freq	0.9826	0.9604	0.9922	0.9811
T2-GloVe	0.9774	0.9500	0.9861	0.9669
T2-W2V-AG	0.9731	0.9402	0.9792	0.9506
T2-W2V-NYT	0.9783	0.9499	0.9887	0.9718
T3-BERT-base 微调	0.9714	0.9365	0.9748	0.9435

词袋可保留具体人名、组织和主题词的独立特征，在本次有强主题线索的新闻上效果较好；缺点是 227,613 维词表高维稀疏、不能直接表达词义和词序，空格切词还保留大量标点词形。Binary 抑制重复信息，Freq 放大出现次数，各有正确和错误案例；本次主实验 Freq 略好。

100 维平均静态词向量更紧凑，可利用语义接近性，并在奥运经济收益等个别交叉主题新闻上优于词袋；但单一词向量不能区分 game 等词的不同语境，平均操作会混合主次主题、丢失词序和局部结构。NYT Word2Vec 在本次三组静态向量中测试表现最好，GloVe 并非所有配置下都最优。

BERT-base 微调的测试 Accuracy/Macro-F1 为 0.9748/0.9435。它可学习上下文和词序，并由标签更新整个编码器，但参数量与计算成本明显增加，本次长度 64 还限制了可利用的正文范围。与五个 LR 方案的比较同时改变了编码器训练方式和截断规则，不能视为只改变表示的一项控制变量实验。

本次是固定种子、固定划分的一次对比。前五种 LR 方案的分类器搜索协议相同，但分词规则、表示学习语料与最优 C 存在差异；不能将总表视为完全排除这些因素的因果比较。前两类表征都远优于仅猜 sports 的多数类基线，而较高 Accuracy 不代表三个类别同样容易。